



File ini merupakan hasil pengerjaan *final project* peserta yang dilakukan dalam kegiatan Kursus Data Science Universitas Gunadarma Periode 02 Juni - 13 Juni 2026 (Semester 8) untuk Skema Ilmuwan Data Madya (*Associate Data Scientist*).

PREDIKSI RESPONSE PELANGGAN TERHADAP CAMPAIGN MARKETING

Disusun Oleh:

- Nama Mahasiswa: Salsa Tashfiyatul Qolbi
- NPM: 51422497
- Kelas Kursus/Kelompok Kursus: Kelas B/Kelompok 2

Daftar Isi

Klik untuk melompat ke unit yang dituju:

1. [UNIT #1 - Mengumpulkan Data](#) J.62DMI00.004.1
2. [UNIT #2 - Menelaah Data](#) J.62DMI00.005.1
3. [UNIT #3 - Memvalidasi Data](#) J.62DMI00.006.1
4. [UNIT #4 - Menentukan Objek Data](#) J.62DMI00.007.1
5. [UNIT #5 - Membersihkan Data](#) J.62DMI00.008.1
6. [UNIT #6 - Mengkonstruksi Data](#) J.62DMI00.009.1
7. [UNIT #7 - Menentukan Label Data](#) J.62DMI00.0010.1
8. [UNIT #8 - Membangun Model](#) J.62DMI00.0013.1
9. [UNIT #9 - Mengevaluasi Hasil Pemodelan](#) J.62DMI00.0014.1

UNIT #1 - Mengumpulkan Data

Kode unit: J.62DMI00.004.1

[Kembali ke Daftar Isi](#)

Elemen - 1 Menentukan kebutuhan data

KUK 1.1. Kebutuhan data diidentifikasi sesuai tujuan teknis data science

Tujuan proyek data science ini adalah untuk membangun model prediksi yang dapat mengidentifikasi apakah seorang pelanggan akan merespons terhadap kampanye (campaign) yang dilakukan perusahaan. Hasilnya dapat membantu perusahaan untuk menargetkan pelanggan yang memiliki peluang lebih tinggi untuk menerima penawaran sehingga biaya pemasaran menjadi lebih efisien dan tingkat keberhasilan campaign dapat meningkat.

Dari tujuan tersebut, dataset Superstore Campaign Marketing dipilih karena memiliki informasi yang relevan untuk memprediksi respons pelanggan terhadap campaign pemasaran. Dataset memuat data demografis pelanggan, data perilaku pembelian pelanggan, data frekuensi transaksi, data frekuensi kunjungan web, dan data riwayat respons pada campaign sebelumnya. Variabel-variabel ini merupakan faktor yang berpotensi memengaruhi keputusan pelanggan dalam menerima atau menolak suatu campaign, sehingga sesuai dengan tujuan dari proyek ini.

KUK 1.2. Kebutuhan data diperiksa ketersediaannya sesuai aturan yang berlaku

Dataset Superstore Campaign Marketing tersedia secara publik dan dapat diakses di website Kaggle melalui link berikut: [Link Dataset](#) Dataset ini merupakan sampel data untuk melakukan analisis bisnis dan tidak mengandung informasi sensitif yang dapat merugikan pihak manapun.

KUK 1.3. Kebutuhan data ditentukan volumenya sesuai tujuan teknis data science

Dalam proyek ini dibutuhkan data pelanggan yang beragam, ini sesuai dengan dataset yang tersedia. Berikut sel untuk mengukur volume data (jumlah baris dan kolom)

```
In [1]: import pandas as pd
df = pd.read_csv('superstore_data.csv')
df.shape
print(f'Jumlah baris: {df.shape[0]}')
print(f'Jumlah kolom: {df.shape[1]}')
```

Jumlah baris: 2240

Jumlah kolom: 22

Elemen 2 - Mengambil data

KUK 2.1. Metode dan tools pengambilan data diidentifikasi sesuai tujuan teknis data science

Data yang digunakan pada proyek ini diperoleh dari platform Kaggle dalam format `.csv`. Karena data tersedia dalam format `.csv` dan telah tersimpan pada penyimpanan lokal, metode pengambilan data dilakukan dengan membaca file secara langsung menggunakan library pandas dengan memanfaatkan fungsi `pd.read_csv()` untuk memuat dataset ke dalam DataFrame sehingga dapat dilakukan proses eksplorasi, pembersihan data, dan pemodelan machine learning.

Tools yang Digunakan

- Python
- Pandas
- Jupyter Notebook

KUK 2.2. Tools pengambilan data ditentukan sesuai tujuan teknis data science

Tools ditentukan untuk mendukung seluruh proses data science mulai dari pengambilan data, eksplorasi data, pembersihan data, transformasi data, pembangunan model, hingga evaluasi model. Tools yang digunakan antara lain:

Kebutuhan	Tools
Pengolahan data	Pandas
Visualisasi	Matplotlib, Seaborn
Preprocessing data	Scikit-Learn
Pembagian data	Scikit-Learn
Imbalance data	Imbalance-Learn
Modelling data	Scikit-Learn
Evaluasi Model	Scikit-Learn
Environment	Jupyter Lab

KUK 2.3. Tools pengambilan data disiapkan sesuai tujuan teknis data science

Berdasarkan kebutuhan analisis data dan pembangunan model machine learning, ditentukan penggunaan Python, Pandas, NumPy, Matplotlib, Seaborn, Imbalance-Learn, dan Scikit-Learn sebagai tools utama.

```
In [62]: # Manipulasi data
import pandas as pd
import numpy as np

# Visualisasi data
import matplotlib.pyplot as plt
import seaborn as sns
```

```

# Preprocessing
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import StandardScaler

# Pembagian data
from sklearn.model_selection import train_test_split

# Penanganan data tidak seimbang
from imblearn.over_sampling import SMOTE

# Algoritma klasifikasi
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier

from sklearn.model_selection import GridSearchCV

# Evaluasi model
from sklearn.metrics import (
    accuracy_score,
    precision_score,
    recall_score,
    f1_score,
    confusion_matrix,
    classification_report
)

```

KUK 2.4. Proses pengambilan data dijalankan sesuai dengan tools yang telah disiapkan

Proses pengambilan data dilakukan dengan membaca file dataset Superstore Marketing Campaign yang berformat .csv menggunakan fungsi `read_csv()` dari library pandas. Dataset kemudian dimuat ke dalam DataFrame agar dapat dilakukan proses eksplorasi, pembersihan data, dan analisis lebih lanjut. Untuk memastikan data berhasil dimuat dengan benar, dilakukan pemeriksaan beberapa baris pertama data menggunakan fungsi `head()`

```
In [3]: df = pd.read_csv('superstore_data.csv')
df.head()
```

```
Out[3]:
```

	Id	Year_Birth	Education	Marital_Status	Income	Kidhome	Teenhome	Dt_Cust
0	1826	1970	Graduation	Divorced	84835.0	0	0	6/16,
1	1	1961	Graduation	Single	57091.0	0	0	6/15,
2	10476	1958	Graduation	Married	67267.0	0	1	5/13,
3	1386	1967	Graduation	Together	32474.0	1	1	11/5,
4	5371	1989	Graduation	Single	21474.0	1	0	8/4,

5 rows × 22 columns



Elemen 3 - Mengintegrasikan data

KUK 3.1. Integritas data diperiksa sesuai tujuan teknis data science

In [4]: `df.info()`

```
<class 'pandas.DataFrame'>
RangeIndex: 2240 entries, 0 to 2239
Data columns (total 22 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Id                     2240 non-null   int64
1   Year_Birth             2240 non-null   int64
2   Education              2240 non-null   str
3   Marital_Status         2240 non-null   str
4   Income                 2216 non-null   float64
5   Kidhome                2240 non-null   int64
6   Teenhome               2240 non-null   int64
7   Dt_Customer            2240 non-null   str
8   Recency                2240 non-null   int64
9   MntWines               2240 non-null   int64
10  MntFruits               2240 non-null   int64
11  MntMeatProducts        2240 non-null   int64
12  MntFishProducts        2240 non-null   int64
13  MntSweetProducts       2240 non-null   int64
14  MntGoldProds           2240 non-null   int64
15  NumDealsPurchases      2240 non-null   int64
16  NumWebPurchases        2240 non-null   int64
17  NumCatalogPurchases    2240 non-null   int64
18  NumStorePurchases      2240 non-null   int64
19  NumWebVisitsMonth      2240 non-null   int64
20  Response               2240 non-null   int64
21  Complain               2240 non-null   int64
dtypes: float64(1), int64(18), str(3)
memory usage: 385.1 KB
```

In [5]: `print(f'Total data hilang/kosong: \n{df.isnull().sum()}')`

Total data hilang/kosong:

Id	0
Year_Birth	0
Education	0
Marital_Status	0
Income	24
Kidhome	0
Teenhome	0
Dt_Customer	0
Recency	0
MntWines	0
MntFruits	0
MntMeatProducts	0
MntFishProducts	0
MntSweetProducts	0
MntGoldProds	0
NumDealsPurchases	0
NumWebPurchases	0
NumCatalogPurchases	0
NumStorePurchases	0
NumWebVisitsMonth	0
Response	0
Complain	0

dtype: int64

```
In [6]: print(f'Jumlah duplikasi data: {df.duplicated().sum()}')
```

Jumlah duplikasi data: 0

Hasil

- Dataset berhasil dibaca dan menampilkan seluruh atribut didalamnya
- Dataset terdiri dari 2240 baris data dan 22 kolom data
- Terdapat ketidaksesuaian tipe data pada atribut Dt_Customer, atribut tersebut seharusnya memiliki tipe data datetime
- Atribut Year_Birth tidak ada masalah hanya saja nilainya kurang informatif, jadi disarankan untuk diubah menjadi atribut Age untuk mempermudah analisis
- Terdapat data kosong/hilang pada atribut Income sebanyak 24 data
- Tidak ditemukan data yang ganda atau terduplikat dan semua baris data bersifat unik

KUK 3.2. Data diintegrasikan sesuai tujuan teknis data science

Data sudah berhasil diperiksa integritasnya, dengan beberapa kekurangan yang ada maka disarankan untuk melakukan:

1. Mengganti tipe data atribut Dt_Customer menjadi datetime, dan menggantinya menjadi kolom Customer_Tenure untuk informasi lama waktu sejak awal terdaftar sebagai pelanggan perusahaan
2. Membuat atribut Age dengan memanfaatkan atribut Year_Birth, dan menghapus atribut Year_Birth
3. Melakukan imputasi pada atribut Income dengan metode median imputation yang kuat terhadap outlier dan dapat mempertahankan distribusi data

4. Dapat menghapus atribut Id karena tidak dibutuhkan dalam pelatihan model dan dapat merusak hasil akhir dari model

Seluruh proses integrasi data tersebut dilakukan ditahap data cleaning.

UNIT #2 - Menelaah Data

Kode unit: J.62DMI00.005.1

[Kembali ke Daftar Isi](#)

Elemen 1 - Menganalisis tipe dan relasi data

KUK 1.1. Tipe data yang terkumpul diidentifikasi sesuai tujuan teknis

```
In [7]: numerical_cols = df.select_dtypes(include=['int64', 'float64']).columns.tolist()
categorical_cols = df.select_dtypes(include=['object', 'category', 'string']).columns.tolist()
target_col = ['Response']

print("=== Data Numerik ===")
print(numerical_cols)

print("\n=== Data Kategorikal ===")
print(categorical_cols)

print("\n=== Target ===")
print(target_col)
```

```
=== Data Numerik ===
['Id', 'Year_Birth', 'Income', 'Kidhome', 'Teenhome', 'Recency', 'MntWines', 'MntFruits', 'MntMeatProducts', 'MntFishProducts', 'MntSweetProducts', 'MntGoldProducts', 'NumDealsPurchases', 'NumWebPurchases', 'NumCatalogPurchases', 'NumStorePurchases', 'NumWebVisitsMonth', 'Response', 'Complain']
```

```
=== Data Kategorikal ===
['Education', 'Marital_Status', 'Dt_Customer']
```

```
=== Target ===
['Response']
```

KUK 1.2. Nilai atribut data yang terkumpul diuraikan sesuai dengan batasan konteks bisnisnya

Setiap atribut diuraikan berdasarkan konteks bisnis untuk memahami perannya dalam analisis respons pelanggan terhadap kampanye marketing.

1. Year_Birth = Usia pelanggan
2. Income = Pendapatan tahunan pelanggan
3. Education = Tingkat pendidikan pelanggan
4. Marital_Status = status pernikahan pelanggan

5. Kidhome = Jumlah anak kecil dalam rumah tangga
6. Teenhome = Jumlah remaja dalam rumah tangga
7. MntWines = Total pengeluaran produk wine
8. MntMeatProducts = Total pengeluaran produk daging
9. MntFishProducts = Total pengeluaran produk ikan
10. MntFruits = Total pengeluaran produk buah
11. MntSweetProducts = Total pengeluaran produk manisan
12. MntGoldProds = Total pengeluaran produk emas
13. NumDealsPurchases = Jumlah pembelian menggunakan diskon
14. NumCatalogPurchases = Jumlah pembelian melalui katalog
15. NumStorePurchases = Jumlah pembelian di toko fisik
16. NumWebPurchases = Jumlah pembelian melalui website
17. NumWebVisitsMonth = Jumlah kunjungan website dalam satu bulan terakhir
18. Recency = Jumlah hari sejak pembelian terakhir
19. Complain = Status keluhan pelanggan dalam 2 tahun terakhir
20. Response = Respons pelanggan terhadap campaign marketing
21. Dt_Customer = Tanggal pendaftaran pelanggan
22. Id = nomor unik pelanggan

In [8]: `df.describe(include='all')`

Out[8]:

	Id	Year_Birth	Education	Marital_Status	Income	Kidhor
count	2240.000000	2240.000000	2240	2240	2216.000000	2240.0000
unique	NaN	NaN	5	8	NaN	NaN
top	NaN	NaN	Graduation	Married	NaN	NaN
freq	NaN	NaN	1127	864	NaN	NaN
mean	5592.159821	1968.805804	NaN	NaN	52247.251354	0.4441
std	3246.662198	11.984069	NaN	NaN	25173.076661	0.5383
min	0.000000	1893.000000	NaN	NaN	1730.000000	0.0000
25%	2828.250000	1959.000000	NaN	NaN	35303.000000	0.0000
50%	5458.500000	1970.000000	NaN	NaN	51381.500000	0.0000
75%	8427.750000	1977.000000	NaN	NaN	68522.000000	1.0000
max	11191.000000	1996.000000	NaN	NaN	666666.000000	2.0000


11 rows × 22 columns



KUK 1.3. Relasi antar data yang terkumpul diidentifikasi sesuai dengan tujuan teknis

In [9]: `corr = df.corr(numeric_only=True)
plt.figure(figsize=(18,12))`

```
sns.heatmap(corr, annot=True)
plt.show()
```




Hasil

- Faktor yang paling berkaitan dengan Response adalah jumlah pembelian produk, terutama wine dan daging, serta jumlah pembelian melalui katalog walaupun nilai korelasi rendah
- Recency menjadi indikator penting karena semakin lama pelanggan tidak bertransaksi, semakin kecil kemungkinan mereka merespons kampanye.
- Atribut total pengeluaran pembelian, seperti MntWines, MntFruits, dan lainnya memiliki korelasi kuat (>0.5) dengan atribut total pembelian "melalui", seperti NumCatalogPurchases, dan lainnya. Hal ini menunjukkan bahwa semakin banyak total yang dikeluarkan untuk membeli, maka semakin banyak total pembelian "melalui".
- Tidak terdapat korelasi yang sangat kuat terhadap target ($\text{Response} > 0.5$), sehingga model machine learning perlu memanfaatkan kombinasi beberapa fitur untuk memperoleh prediksi yang lebih akurat

```
In [10]: response_corr = corr['Response'].drop('Response')
response_corr = response_corr.sort_values()

plt.figure(figsize=(10,6))
response_corr.plot(kind='barh')
plt.title('Correlation of Features with Response')
plt.xlabel('Correlation Coefficient')
plt.ylabel('Features')
plt.grid(axis='x', linestyle='--', alpha=0.7)
```

```
plt.tight_layout()
plt.show()
```



Visualisasi tersebut bertujuan untuk memudahkan melihat atribut apa yang memiliki korelasi dengan atribut target (Response), baik itu korelasi positif atau korelasi negatif

Elemen 2 - Menganalisis karakteristik data

KUK 2.1. Karakteristik data yang terkumpul disajikan dengan deskripsi statistik dasar

```
In [11]: df.describe(include='all')
```

Out[11]:

	Id	Year_Birth	Education	Marital_Status	Income	Kidhor
count	2240.000000	2240.000000	2240	2240	2216.000000	2240.0000
unique	NaN	NaN	5	8	NaN	NaN
top	NaN	NaN	Graduation	Married	NaN	NaN
freq	NaN	NaN	1127	864	NaN	NaN
mean	5592.159821	1968.805804	NaN	NaN	52247.251354	0.4441
std	3246.662198	11.984069	NaN	NaN	25173.076661	0.5383
min	0.000000	1893.000000	NaN	NaN	1730.000000	0.0000
25%	2828.250000	1959.000000	NaN	NaN	35303.000000	0.0000
50%	5458.500000	1970.000000	NaN	NaN	51381.500000	0.0000
75%	8427.750000	1977.000000	NaN	NaN	68522.000000	1.0000
max	11191.000000	1996.000000	NaN	NaN	66666.000000	2.0000

11 rows × 22 columns





KUK 2.2. Karakteristik data yang terkumpul disajikan dengan visualisasi grafik

KUK 2.3. Hasil penyajian data dianalisis karakteristiknya untuk telaah data


```
In [12]: numerical_cols = df.select_dtypes(include=['int64', 'float64']).columns.tolist()

if 'Response' in numerical_cols:
    numerical_cols.remove('Response')


# Plot histogram untuk seluruh data numerik
for col in numerical_cols:
    plt.figure(figsize=(7,4))
    sns.histplot(df[col], kde=True)
    plt.title(f'Distribusi {col}')
    plt.xlabel(col)
    plt.ylabel('Frekuensi')
    plt.show()
```





Distribusi Income




Distribusi Kidhome







Distribusi MntWines




Distribusi MntFruits




Distribusi MntMeatProducts




Distribusi MntFishProducts







Distribusi MntSweetProducts





Distribusi MntGoldProds











```
In [13]: categorical_cols = ['Education', 'Marital_Status']
```

```
for col in categorical_cols:  
    plt.figure(figsize=(6,4))  
    sns.countplot(x=col, data=df)  
    plt.title(f'Distribusi {col}')  
    plt.xticks(rotation=45)  
    plt.show()
```




Hasil:

- Distribusi atribut Education didominasi oleh orang dewasa dengan pendidikan menengah hingga tinggi
- Distribusi atribut Marital_Status didominasi oleh orang yang sudah menikah

- Terdapat kategori kotor, yaitu YOLO, Alone, dan Absurd dengan jumlah sedikit, disarankan untuk disatukan dengan kategori Single atau bisa dihapus karena data sedikit. Hanya saja dikhawatirkan memuat informasi penting jadi lebih baik disatukan dengan kategori Single dibandingkan harus dihapus.


```
In [14]: plt.figure(figsize=(8,5))
sns.countplot(x='Response', data=df)
plt.title('Income berdasarkan Response')
plt.show()
```



Hasil:

- Distribusi data pada atribut Response tidak seimbang, banyak data dikategori 0 (Tidak merespons campaign)
- Disarankan melakukan penyeimbangan data dengan SMOTE atau weight kelas


```
In [15]: plt.figure(figsize=(8,5))
sns.boxplot(x='Response', y='Income', data=df)
plt.title('Income berdasarkan Response')
plt.show()
```



Hasil:

- Terdapat outlier pada kategori 0
- Berdasarkan boxplot Income berdasarkan Response, pelanggan yang merespons campaign (Response = 1) cenderung memiliki median pendapatan yang lebih tinggi dibandingkan pelanggan yang tidak merespons campaign (Response = 0).

```
In [16]: plt.figure(figsize=(8,5))
sns.boxplot(x='Response', y='Recency', data=df)
plt.title('Recency berdasarkan Response')
plt.show()
```

**Hasil:**

- Berdasarkan boxplot Recency berdasarkan Response, pelanggan yang merespons campaign marketing (Response = 1) memiliki nilai median Recency yang lebih rendah dibandingkan pelanggan yang tidak merespons campaign (Response = 0).
- Nilai Recency yang lebih rendah menunjukkan pelanggan melakukan transaksi dalam waktu yang lebih dekat dengan periode campaign. Sebaliknya, pelanggan dengan nilai Recency yang lebih tinggi cenderung sudah lama tidak melakukan pembelian.

Elemen 3 - Membuat laporan telaah data

KUK 3.1. Hasil analisis didokumentasikan dalam bentuk laporan sesuai dengan tujuan teknis

Hasil analisis menunjukkan bahwa dataset Marketing Campaign memiliki karakteristik yang mendukung pembangunan model klasifikasi untuk memprediksi respons pelanggan terhadap campaign marketing.

Beberapa temuan penting yang diperoleh antara lain:

1. Variabel target Response memiliki distribusi kelas yang tidak seimbang.
2. Variabel Income mengandung beberapa nilai ekstrem (outlier).
3. Pelanggan dengan pendapatan yang lebih tinggi cenderung memberikan respons positif terhadap campaign marketing.
4. Variabel demografi dan perilaku pembelian berpotensi memberikan kontribusi terhadap prediksi respons pelanggan.
5. Terdapat kategori noise pada atribut Marital_Status

6. Kategori di atribut Education seperti Master dan 2n Cycle akan dijadikan 1, dan kategori lain akan diubah namanya sesuai dengan tingkatannya

Hasil analisis ini menjadi dasar dalam menentukan strategi preprocessing, pemilihan fitur, serta pembangunan model machine learning pada tahap selanjutnya.

KUK 3.2. Hipotesis disusun berdasar hasil analisis sesuai tujuan teknis data science

H₁: Pelanggan dengan pendapatan (Income) yang lebih tinggi memiliki kecenderungan lebih besar untuk merespons campaign marketing dibandingkan pelanggan dengan pendapatan yang lebih rendah.

H₂: Karakteristik demografis pelanggan seperti usia, tingkat pendidikan, dan status pernikahan memengaruhi respons pelanggan terhadap campaign marketing.

H₃: Perilaku pembelian pelanggan, seperti jumlah transaksi melalui website, katalog, maupun toko fisik, berpengaruh terhadap keberhasilan campaign marketing.

H₄: Informasi demografi pelanggan dan perilaku pembelian dapat digunakan untuk membangun model klasifikasi yang mampu memprediksi respons pelanggan terhadap campaign marketing dengan performa yang baik.

H₅: Pelanggan dengan nilai Recency yang lebih rendah memiliki kemungkinan lebih besar untuk merespons campaign marketing dibandingkan pelanggan dengan nilai Recency yang lebih tinggi.

UNIT #3 - Memvalidasi Data

Kode unit: J.62DMI00.006.1

[Kembali ke Daftar Isi](#)

Elemen 1 - Melakukan pengecekan kelengkapan data

KUK 1.1. Penilaian kualitas data dari hasil telaah disajikan sesuai tujuan teknis data science

Berdasarkan hasil telaah data pada Unit 2, dilakukan penilaian kualitas data untuk mengetahui apakah terdapat masalah yang dapat memengaruhi proses analisis dan pemodelan. Penilaian dilakukan terhadap missing value, duplikasi data, konsistensi tipe data, dan validitas nilai atribut.

```
In [17]: print(f'Jumlah data kosong/hilang: \n{df.isnull().sum()}')
```

Jumlah data kosong/hilang:

```

Id          0
Year_Birth  0
Education   0
Marital_Status  0
Income      24
Kidhome     0
Teenhome    0
Dt_Customer 0
Recency     0
MntWines    0
MntFruits   0
MntMeatProducts  0
MntFishProducts  0
MntSweetProducts  0
MntGoldProds  0
NumDealsPurchases  0
NumWebPurchases  0
NumCatalogPurchases  0
NumStorePurchases  0
NumWebVisitsMonth  0
Response    0
Complain    0
dtype: int64

```

```
In [18]: print(f'Jumlah data duplikasi: {df.duplicated().sum()}')
```

Jumlah data duplikasi: 0

```
In [19]: df.info()
```

```

<class 'pandas.DataFrame'>
RangeIndex: 2240 entries, 0 to 2239
Data columns (total 22 columns):
 #   Column                Non-Null Count  Dtype
---  -
 0   Id                    2240 non-null   int64
 1   Year_Birth            2240 non-null   int64
 2   Education             2240 non-null   str
 3   Marital_Status        2240 non-null   str
 4   Income                2216 non-null   float64
 5   Kidhome               2240 non-null   int64
 6   Teenhome              2240 non-null   int64
 7   Dt_Customer           2240 non-null   str
 8   Recency               2240 non-null   int64
 9   MntWines              2240 non-null   int64
10  MntFruits             2240 non-null   int64
11  MntMeatProducts        2240 non-null   int64
12  MntFishProducts        2240 non-null   int64
13  MntSweetProducts       2240 non-null   int64
14  MntGoldProds          2240 non-null   int64
15  NumDealsPurchases      2240 non-null   int64
16  NumWebPurchases        2240 non-null   int64
17  NumCatalogPurchases    2240 non-null   int64
18  NumStorePurchases      2240 non-null   int64
19  NumWebVisitsMonth      2240 non-null   int64
20  Response              2240 non-null   int64
21  Complain              2240 non-null   int64
dtypes: float64(1), int64(18), str(3)
memory usage: 385.1 KB

```

Hasil:

Aspek Kualitas	Hasil
Missing Value	Ditemukan pada atribut Income
Duplikasi	Tidak ditemukan data duplikat
Tipe Data	Ketidaksesuaian tipe data pada atribut Dt_Customer

KUK 1.2. Penilaian tingkat kecukupan data dari hasil telaah disajikan sesuai tujuan teknis data science

```
In [20]: df.shape
```

```
Out[20]: (2240, 22)
```

```
In [21]: df["Response"].value_counts()
```

```
Out[21]: Response
0      1906
1       334
Name: count, dtype: int64
```

```
In [22]: round(df["Response"].value_counts(normalize=True)*100, 2)
```

```
Out[22]: Response
0      85.09
1      14.91
Name: proportion, dtype: float64
```

Hasil:

- Dataset memiliki 2240 record pelanggan.
- Dataset memiliki atribut demografis, perilaku pembelian, dan histori kampanye yang relevan.
- Variabel target Response tersedia.

Jumlah data dinilai cukup untuk pembangunan model machine learning klasifikasi.

Elemen 2 - Membuat rekomendasi kelengkapan data

KUK 2.1. Rekomendasi hasil penilaian kualitas disusun sesuai tujuan teknis data science

Berdasarkan hasil penilaian kualitas data, disusun rekomendasi untuk meningkatkan kualitas dataset sebelum digunakan pada tahap konstruksi dan pemodelan. Rekomendasi tindakan:

1. Melakukan missing value pada atribut Income dengan metode median imputasi

2. Mengganti tipe data pada atribut Dt_Customer menjadi datetime, dan mengubahnya menjadi kolom Customer_Tenure untuk melihat berapa lama pelanggan terdaftar diperusahaan
3. Menghapus outlier pada Income, karena data outlier tidak banyak dan cenderung berada di kategori 0 pada atribut Response
4. Melakukan validasi setelah melakukan pembersihan data

KUK 2.2. Rekomendasi hasil penilaian kecukupan data disusun sesuai tujuan teknis data science

Berdasarkan hasil penilaian kecukupan data, disusun rekomendasi terkait kelayakan dataset untuk digunakan dalam pembangunan model machine learning.

Rekomendasi:

1. Dataset dapat digunakan untuk pembangunan model klasifikasi karena jumlah data cukup.
2. Variabel target Response sudah tersedia sehingga tidak diperlukan proses pelabelan tambahan.
3. Ketidakseimbangan kelas pada Response perlu diperhatikan saat proses pemodelan.
4. Evaluasi model sebaiknya menggunakan metrik selain accuracy, seperti Precision, Recall, dan F1-Score.

UNIT #4 - Menentukan Objek Data

Kode unit: J.62DMI00.007.1

[Kembali ke Daftar Isi](#)

Elemen 1 - Memutuskan kriteria dan teknik pemilihan data

KUK 1.1. Kriteria pemilihan data diidentifikasi sesuai dengan tujuan teknis dan aturan yang berlaku

Pemilihan data dilakukan untuk memastikan bahwa atribut yang digunakan memiliki relevansi terhadap tujuan pembangunan model klasifikasi respons pelanggan terhadap campaign marketing.

Kriteria	Keputusan
Memiliki hubungan dengan perilaku pelanggan	Dipertahankan
Memiliki hubungan dengan target Response	Dipertahankan
Merupakan identifier unik	Dihapus
Tidak memiliki informasi prediktif	Dipertimbangkan untuk dihapus

KUK 1.2. Teknik pemilihan data ditetapkan sesuai dengan kriteria pemilihan data

Teknik pemilihan data dilakukan menggunakan feature selection berdasarkan atribut yang memiliki pengaruh terhadap respons pelanggan terhadap campaign marketing.

Atribut yang tidak relevan seperti ID pelanggan tidak dipilih karena tidak memiliki kontribusi terhadap proses prediksi. Sementara atribut yang berkaitan dengan demografi pelanggan, perilaku pembelian, aktivitas website, dan interaksi pelanggan dipertahankan karena berpotensi memengaruhi variabel target.

```
In [23]: df_selected = df.copy()
df_selected = df.drop(columns=["Id"])
df_selected.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 2240 entries, 0 to 2239
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Year_Birth             2240 non-null   int64
1   Education              2240 non-null   str
2   Marital_Status         2240 non-null   str
3   Income                 2216 non-null   float64
4   Kidhome                2240 non-null   int64
5   Teenhome               2240 non-null   int64
6   Dt_Customer            2240 non-null   str
7   Recency                2240 non-null   int64
8   MntWines               2240 non-null   int64
9   MntFruits              2240 non-null   int64
10  MntMeatProducts        2240 non-null   int64
11  MntFishProducts        2240 non-null   int64
12  MntSweetProducts       2240 non-null   int64
13  MntGoldProds           2240 non-null   int64
14  NumDealsPurchases      2240 non-null   int64
15  NumWebPurchases        2240 non-null   int64
16  NumCatalogPurchases    2240 non-null   int64
17  NumStorePurchases      2240 non-null   int64
18  NumWebVisitsMonth       2240 non-null   int64
19  Response               2240 non-null   int64
20  Complain               2240 non-null   int64
dtypes: float64(1), int64(17), str(3)
memory usage: 367.6 KB
```

Elemen 2 - Menentukan attributes (columns) dan records (row) data

KUK 2.1. Attributes (columns) data diidentifikasi sesuai dengan kriteria pemilihan data

Atribut dipilih berdasarkan relevansinya terhadap perilaku pelanggan dan kemungkinan pengaruhnya terhadap keberhasilan kampanye marketing.

Atribut yang Digunakan

Demografi

1. Year_Birth
2. Education
3. Marital_Status
4. Income
5. Kidhome
6. Teenhome

Perilaku Pembelian

1. Recency
2. Dt_Customer
3. MntWines
4. MntFruits
5. MntMeatProducts
6. MntFishProducts
7. MntSweetProducts
8. MntGoldProds
9. NumDealsPurchases
10. NumWebPurchases
11. NumCatalogPurchases
12. NumStorePurchases
13. NumWebVisitsMonth

Riwayat Kampanye

1. Complain

Target

1. Response

KUK 2.2. Records (row) data diidentifikasi sesuai dengan kriteria pemilihan data

Record yang digunakan adalah seluruh data pelanggan yang memenuhi kriteria kualitas data dan memiliki informasi yang dapat digunakan dalam analisis.

```
In [24]: print(f' Jumlah baris dan kolom yang sesuai kriteria pemilihan data: {df_selecte
```

Jumlah baris dan kolom yang sesuai kriteria pemilihan data: (2240, 21)

UNIT #5 - Membersihkan Data

Kode unit: J.62DMI00.008.1

[Kembali ke Daftar Isi](#)

Elemen 1 - Melakukan pembersihan data yang kotor

KUK 1.1. Strategi pembersihan data ditentukan berdasarkan hasil telaah data

Berdasarkan hasil validasi data pada Unit 3, ditemukan beberapa kondisi yang memerlukan tindakan pembersihan data sebelum digunakan untuk pemodelan.

Strategi pembersihan ditentukan sebagai berikut:

Masalah Data	Strategi
Missing value pada Income	Imputasi menggunakan median
Tipe data Dt_Customer	Konversi ke datetime
Nilai ekstrem (outlier)	Menghapus nilai outlier pada Income

KUK 1.2. Data yang kotor dikoreksi berdasarkan strategi pembersihan data

Proses pembersihan data dilakukan sesuai strategi yang telah ditetapkan. Proses pembersihan dilakukan untuk menghasilkan dataset yang lebih konsisten dan siap digunakan pada tahap konstruksi data.

```
In [25]: df_clean = df_selected.copy()
df_clean["Income"] = df_clean["Income"].fillna(df_clean["Income"].median())

In [26]: df_clean["Dt_Customer"] = pd.to_datetime(df_clean["Dt_Customer"], format='%m/%d/

In [27]: Q1 = df_clean['Income'].quantile(0.25)
Q3 = df_clean['Income'].quantile(0.75)

IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

df_clean = df_clean[
    (df_clean['Income'] >= lower_bound) &
    (df_clean['Income'] <= upper_bound)
]
```

Elemen 2 - Membuat laporan dan rekomendasi hasil membersihkan data

KUK 2.1. Masalah dan teknis koreksi data dideskripsikan sesuai dengan kondisi data dan strategi pembersihan data

Masalah dan tekni koreksi data dilakukan dengan alasan:

1. Median Imputation cocok dengan dataset yang memiliki outlier, karena metode ini kuat terhadap outlier dan mempertahankan distribusi data
2. Mengubah tipe data Dt_Customer dilakukan untuk menjaga konsistensi tipe data
3. Nilai outlier Income dihapus menggunakan metode IQR karena data outlier berada pada kategori 0 (Tidak memberi Respons) pada Response, selain itu data pada kategori ini lebih banyak dibanding kategori 1 (Memberi Respons)

KUK 2.2. Evaluasi dihasilkan berdasarkan analisis koreksi yang telah dilakukan

```
In [28]: print("=== Missing Value Sebelum Penanganan ===")
print(df.isnull().sum())

print("\nTotal Missing Value:")
print(df.isnull().sum().sum())

print("\n=== Missing Value Setelah Penanganan ===")
print(df_clean.isnull().sum())

print("\nTotal Missing Value:")
print(df_clean.isnull().sum().sum())
```

```
=== Missing Value Sebelum Penanganan ===
```

```
Id                0
Year_Birth        0
Education          0
Marital_Status    0
Income            24
Kidhome           0
Teenhome          0
Dt_Customer       0
Recency           0
MntWines          0
MntFruits         0
MntMeatProducts   0
MntFishProducts   0
MntSweetProducts  0
MntGoldProds      0
NumDealsPurchases 0
NumWebPurchases   0
NumCatalogPurchases 0
NumStorePurchases 0
NumWebVisitsMonth 0
Response          0
Complain          0
dtype: int64
```

```
Total Missing Value:
24
```

```
=== Missing Value Setelah Penanganan ===
```

```
Year_Birth        0
Education          0
Marital_Status    0
Income            0
Kidhome           0
Teenhome          0
Dt_Customer       0
Recency           0
MntWines          0
MntFruits         0
MntMeatProducts   0
MntFishProducts   0
MntSweetProducts  0
MntGoldProds      0
NumDealsPurchases 0
NumWebPurchases   0
NumCatalogPurchases 0
NumStorePurchases 0
NumWebVisitsMonth 0
Response          0
Complain          0
dtype: int64
```

```
Total Missing Value:
0
```

```
In [29]: print("=== Tipe Data Sebelum ===")
         print(df.dtypes)

         print("\n=== Tipe Data Sesudah ===")
         print(df_clean.dtypes)
```

=== Tipe Data Sebelum ===

```

Id                int64
Year_Birth        int64
Education         str
Marital_Status    str
Income            float64
Kidhome           int64
Teenhome          int64
Dt_Customer       str
Recency           int64
MntWines          int64
MntFruits         int64
MntMeatProducts  int64
MntFishProducts  int64
MntSweetProducts int64
MntGoldProds     int64
NumDealsPurchases int64
NumWebPurchases  int64
NumCatalogPurchases int64
NumStorePurchases int64
NumWebVisitsMonth int64
Response          int64
Complain          int64
dtype: object

```

=== Tipe Data Sesudah ===

```

Year_Birth        int64
Education         str
Marital_Status    str
Income            float64
Kidhome           int64
Teenhome          int64
Dt_Customer       datetime64[us]
Recency           int64
MntWines          int64
MntFruits         int64
MntMeatProducts  int64
MntFishProducts  int64
MntSweetProducts int64
MntGoldProds     int64
NumDealsPurchases int64
NumWebPurchases  int64
NumCatalogPurchases int64
NumStorePurchases int64
NumWebVisitsMonth int64
Response          int64
Complain          int64
dtype: object

```

```

In [30]: print("Jumlah Data Sebelum Hapus Outlier:", len(df))
         print("Jumlah Data Sesudah Hapus Outlier:", len(df_clean))
         print(f"Data yang terhapus: {len(df) - len(df_clean)}")

```

```

Jumlah Data Sebelum Hapus Outlier: 2240
Jumlah Data Sesudah Hapus Outlier: 2232
Data yang terhapus: 8

```

```

In [31]: df_clean.info()

```

```

<class 'pandas.DataFrame'>
Index: 2232 entries, 0 to 2239
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Year_Birth             2232 non-null   int64
1   Education              2232 non-null   str
2   Marital_Status         2232 non-null   str
3   Income                 2232 non-null   float64
4   Kidhome                2232 non-null   int64
5   Teenhome               2232 non-null   int64
6   Dt_Customer            2232 non-null   datetime64[us]
7   Recency                2232 non-null   int64
8   MntWines               2232 non-null   int64
9   MntFruits              2232 non-null   int64
10  MntMeatProducts        2232 non-null   int64
11  MntFishProducts        2232 non-null   int64
12  MntSweetProducts       2232 non-null   int64
13  MntGoldProds           2232 non-null   int64
14  NumDealsPurchases      2232 non-null   int64
15  NumWebPurchases        2232 non-null   int64
16  NumCatalogPurchases    2232 non-null   int64
17  NumStorePurchases      2232 non-null   int64
18  NumWebVisitsMonth      2232 non-null   int64
19  Response               2232 non-null   int64
20  Complain               2232 non-null   int64
dtypes: datetime64[us](1), float64(1), int64(17), str(2)
memory usage: 383.6 KB

```

```
In [32]: print(f'Banyak duplikasi data setelah pembersihan data: {df_clean.duplicated().sum()}')
```

Banyak duplikasi data setelah pembersihan data: 182

```
In [33]: duplicate_df = df_clean[df_clean.duplicated()].copy()

duplicate_df
```

Out[33]:

	Year_Birth	Education	Marital_Status	Income	Kidhome	Teenhome	Dt_Customer
9	1954	PhD	Married	65324.0	0	1	2014-11-0
27	1956	Graduation	Together	54450.0	1	1	2012-09-1
81	1969	Graduation	Together	68695.0	0	0	2014-06-2
96	1962	Master	Married	58646.0	0	1	2013-10-0
123	1978	Graduation	Married	33039.0	1	0	2013-09-0
...	...	...	...	...	...	...	...
2196	1967	PhD	Married	77766.0	0	1	2013-02-2
2208	1972	Graduation	Together	84906.0	0	0	2013-04-1
2225	1966	Graduation	Married	44794.0	0	1	2014-08-0
2230	1974	2n Cycle	Married	20130.0	0	0	2014-03-1
2232	1973	Graduation	Widow	42429.0	0	1	2014-11-0

182 rows × 21 columns



Catatan: Terdapat duplicate value karena kolom Id dihilangkan, mengakibatkan karakteristik unik setiap baris juga hilang. Namun hal ini wajar karena pada data bisnis wajar jika pelanggan memiliki riwayat dan perilaku yang kebetulan sama

KUK 2.3. Evaluasi proses dan hasilnya didokumentasikan

Hasil evaluasi proses pembersihan data didokumentasikan sebagai bukti bahwa dataset telah memenuhi kualitas yang dibutuhkan untuk tahap konstruksi data dan pemodelan.

```
In [34]: df_clean.to_csv("marketing_campaign_clean.csv", index=False)
```

UNIT #6 - Mengkonstruksi Data

Kode unit: J.62DMI00.009.1

[Kembali ke Daftar Isi](#)

Elemen 1 - Menganalisis teknik transformasi data

KUK 1.1. Analisis data untuk menentukan representasi fitur data awal

Representasi fitur awal:

Fitur kategorikal: 'Education', 'Marital_Status', diproses dengan melakukan Encoding agar menjadi fitur numerik

Fitur numerik: 'Income', 'Kidhome', 'Teenhome', 'Recency', 'MntWines', 'MntFruits', 'MntMeatProducts', 'MntFishProducts', 'MntSweetProducts', 'MntGoldProds', 'NumDealsPurchases', 'NumWebPurchases', 'NumCatalogPurchases', 'NumStorePurchases', 'NumWebVisitsMonth', diproses dengan standarisasi agar menyamakan skala nilai pada masing-masing fitur

Fitur biner: 'Complain', tidak perlu untuk di encoding

Fitur time series: 'Dt_Customer', 'Year_Birth', Dt_Customer dijadikan fitur Customer_Tenure agar lebih informatif, sama halnya dengan Year_Birth dijadikan fitur Age

KUK 1.2. Analisis representasi fitur data awal untuk menentukan teknik rekayasa fitur yang diperlukan untuk pembangunan model data science

Rekayasa fitur yang relevan:

Customer_Tenure data berapa lama pelanggan terdaftar diperusahaan dengan memanfaatkan tanggal pendaftaran Dt_Customer

Age umur pelanggan dengan memanfaatkan tahun kelahirannya pada Year_Birth

Marital_Status menggabungkan kategori YOLO, Alone, dan Absurd ke dalam kategori Single

Education menggabungkan kategori 2n cycle dengan Master menjadi 1 kategori dengan nama 2nd Cycle, kategori Graduation diubah menjadi 1st Cycle, kategori PhD diubah menjadi 3rd Cycle, sedangkan kategori Basic tidak diubah.

Elemen 2 - Melakukan transformasi data

KUK 2.1. Transformasi dilakukan untuk mendapatkan fitur data awal

Transformasi kategori pada fitur Marital_Status

```
In [35]: df_clean['Marital_Status'] = df_clean['Marital_Status'].replace({
    'YOLO': 'Single',
    'Alone': 'Single',
    'Absurd': 'Single'
})
```

Transformasi kategori pada fitur Education

```
In [36]: df_clean['Education'] = df_clean['Education'].replace({
    'Graduation': '1st Cycle',
```

```
'2n Cycle': '2nd Cycle',
'Master': '2nd Cycle',
'PhD': '3rd Cycle'
})
```

KUK 2.2. Rekayasa fitur data dilakukan untuk mendapatkan fitur baru yang diperlukan untuk pembangunan model data science

Menambahkan fitur Age dan menghapus fitur Year_Birth

```
In [37]: reference_year = df_clean['Dt_Customer'].dt.year.max()
df_clean['Age'] = reference_year - df_clean['Year_Birth']
```

```
In [38]: df_clean = df_clean.drop(columns=['Year_Birth'])
```

Menambahkan fitur Customer_Tenure dan menghapus fitur Dt_Customer

```
In [39]: reference_date = df_clean['Dt_Customer'].max()
df_clean['Customer_Tenure'] = ((reference_date - df_clean['Dt_Customer']).dt.day
```

```
In [40]: df_clean = df_clean.drop(columns=['Dt_Customer'])
```

Label encoding pada fitur kategorikal

```
In [41]: education_map = {
    'Basic': 0,
    '1st Cycle': 1,
    '2nd Cycle': 2,
    '3rd Cycle': 3
}
df_clean['Education'] = df_clean['Education'].map(education_map)
```

```
In [42]: df_clean = pd.get_dummies(
    df_clean,
    columns=['Marital_Status'],
    drop_first=True
)
```

Standarisasi fitur numerik

```
In [43]: scale_cols = ['Income', 'Recency', 'MntWines', 'MntFruits',
    'MntMeatProducts', 'MntFishProducts',
    'MntSweetProducts', 'MntGoldProds',
    'NumDealsPurchases', 'NumWebPurchases',
    'NumCatalogPurchases', 'NumStorePurchases',
    'NumWebVisitsMonth', 'Age', 'Customer_Tenure']

scaler = StandardScaler()

df_clean[scale_cols] = scaler.fit_transform(df_clean[scale_cols])
```

Elemen 3 - Membuat dokumentasi konstruksi data

KUK 3.1. Teknis transformasi data dijabarkan dalam bentuk tertulis

Transformasi yang dilakukan pada fitur meliputi:

1. Mengubah kategori pada fitur Marital_Status dengan menggabungkan kategori noise (YOLO, Alone, Absurd) kedalam 1 kategori yaitu Single
2. Mengubah kategori pada fitur Education agar lebih mudah dipahami
3. Melakukan standarisasi pada fitur numerik, terkecuali fitur Kidhome dan Teenhome karena memiliki rentang data yang kecil (0-2) saja
4. Membuat fitur Age dengan memanfaatkan fitur Year_Birth dan menggunakan batas atas tahun yang digunakan dalam dataset yaitu tahun 2014
5. Membuat fitur Customer_Tenure dengan memanfaatkan fitur Dt_Customer dan menggunakan batas atas tanggal dalam dataset yaitu 2014
6. Menghapus fitur Year_Birth dan Dt_Customer
7. Melakukan label encoding pada fitur Education
8. Melakukan one hot encoding pada fitur Marital_Status

KUK 3.2. Hasil transformasi data dan rekomendasi hasil transformasi dituangkan dalam bentuk tertulis

Sebelum Transformasi	Setelah Transformasi
Education (kategori)	Education (numerik hasil label encoding)
Marital_Status (kategori)	Marital_Status (numerik hasil one hot encoding)
Dt_Customer	Customer_Tenure
Year_Birth	Age
Fitur numerik dengan skala berbeda	Fitur numerik terstandarisasi

```
In [44]: scaled_df = pd.DataFrame(
    df_clean[scale_cols],
    columns=scale_cols
)
scaled_df.agg(['min', 'max']).T
```

Out[44]:

	min	max
Income	-2.422720	3.015142
Recency	-1.696622	1.723492
MntWines	-0.905618	3.528472
MntFruits	-0.662614	4.335803
MntMeatProducts	-0.753671	7.110391
MntFishProducts	-0.688489	4.048398
MntSweetProducts	-0.657260	5.708289
MntGoldProds	-0.846213	6.089609
NumDealsPurchases	-1.223808	6.695228
NumWebPurchases	-1.477114	8.255755
NumCatalogPurchases	-0.943072	9.073623
NumStorePurchases	-1.791854	2.218670
NumWebVisitsMonth	-2.207921	6.074565
Age	-2.269622	6.322552
Customer_Tenure	-2.204149	2.369414

In [45]: df_clean.head()

Out[45]:

	Education	Income	Kidhome	Teenhome	Recency	MntWines	MntFruits	MntMe
0	1	1.612078	0	0	-1.696622	-0.344303	1.949624	
1	1	0.265090	0	0	-1.696622	0.472425	-0.537025	
2	1	0.759141	0	1	-1.696622	-0.507649	-0.386319	
3	1	-0.930080	1	1	-1.696622	-0.875919	-0.662614	
4	1	-1.464137	1	0	-1.696622	-0.887798	-0.260731	

5 rows × 24 columns



UNIT #7 - Menentukan Label Data

Kode unit: J.62DMI00.010.1

[Kembali ke Daftar Isi](#)

Elemen 1 - Melakukan pelabelan data

KUK 1.1. Analisis hasil pelabelan data sejenis yang sudah ada diuraikan kesesuaiannya dengan Standard Operating Procedure (SOP) pelabelan

Label yang tersedia pada dataset telah sesuai. Variabel target yang digunakan adalah Response, yang menunjukkan apakah pelanggan merespons kampanye pemasaran yang diberikan perusahaan. Nilai label pada Response:

0 = Pelanggan tidak merespons kampanye

1 = Pelanggan merespons kampanye

```
In [46]: df_clean['Response'].value_counts()
```

```
Out[46]: Response
0      1898
1       334
Name: count, dtype: int64
```

```
In [47]: df_clean['Response'].unique()
```

```
Out[47]: array([1, 0])
```

KUK 1.2. Pelabelan data dilakukan sesuai dengan SOP pelabelan

Karena dataset telah menyediakan label Response, maka tidak ada proses pelabelan manual. Label data sudah sesuai dengan SOP yaitu sudah bertipe numerik dan binary. Dilakukan pemisahan label dengan fitur lain, karena label tidak masuk ke dalam proses trainig

```
In [52]: X = df_clean.drop('Response', axis=1)
y = df_clean['Response']
```

Elemen 2 - Membuat laporan hasil pelabelan data

KUK 2.1. Statistik hasil pelabelan diuraikan pada laporan


Label pada dataset telah tersedia pada fitur Response. Untuk distribusi data pada label tidak seimbang, label 0 (Tidak merespons kampanye) memiliki data yang lebih banyak dibandingkan dengan label 1 (Merespons kampanye). Untuk persentase dan visualisasi data label dapat dilihat di bawah

```
In [54]: round(y.value_counts(normalize=True) * 100, 2)
```

```
Out[54]: Response
0      85.04
1      14.96
Name: proportion, dtype: float64
```

```
In [55]: y.value_counts().plot(kind='bar')
```

```
plt.title('Distribusi Label Response')  
plt.xlabel('Response')  
plt.ylabel('Jumlah Data')  
plt.show()
```



KUK 2.2. Evaluasi proses pelabelan diuraikan pada laporan

Aspek Evaluasi	Hasil
Ketersediaan Label	Tersedia
Tipe Label	Biner
Missing Value	Tidak ada
Keseimbangan Kelas	Tidak seimbang

Rekomendasi:

1. Menggunakan penanganan imbalance seperti class weighting
2. Menggunakan stratified split saat pembagian data training dan testing

UNIT #8 - Membangun Model

Kode unit: J.62DMI00.013.1

[Kembali ke Daftar Isi](#)

Elemen 1 - Menyiapkan parameter model

KUK 1.1. Parameter-parameter yang sesuai dengan model diidentifikasi

Setelah data melalui tahap konstruksi data, selanjutnya data dibagi menjadi data training dan data testing untuk pembangunan dan pengujian model. Karena distribusi kelas Response tidak seimbang, digunakan parameter `class_weight='balanced'` pada algoritma yang mendukung untuk memberikan bobot lebih besar pada kelas minoritas (dilakukan di KUK 2.2)

```
In [56]: X_train, X_test, y_train, y_test = train_test_split(  
        X,  
        y,  
        test_size=0.2,  
        stratify=y,  
        random_state=42  
    )
```

```
In [58]: X_train.shape
```

```
Out[58]: (1785, 23)
```

```
In [59]: y_train.shape
```

```
Out[59]: (1785,)
```

KUK 1.2. Nilai toleransi parameter evaluasi pengujian ditetapkan sesuai dengan tujuan teknis

Karena distribusi data Response tidak seimbang, maka dilakukan evaluasi model tidak hanya dengan akurasi tetapi juga dengan Precision, Recall, dan F1-Score

Metrik	Fungsi
Accuracy	Mengukur ketepatan keseluruhan model
Precision	Mengukur ketepatan prediksi kelas positif
Recall	Mengukur kemampuan model mendeteksi pelanggan yang merespons
F1-Score	Mengukur keseimbangan antara Precision dan Recall

Elemen 2 - Menggunakan tools pemodelan

KUK 2.1. Tools untuk membuat model diidentifikasi sesuai dengan tujuan teknis data science

Model yang akan digunakan:

1. Decision Tree -> dapat menangkap pola non linear

2. Random Forest -> tidak membutuhkan hubungan linear, dapat menangkap interaksi antar fitur, dan dapat memilih fitur yang penting
3. SVM -> cocok untuk data yang tidak memiliki korelasi yang kuat

Tools yang digunakan:

Tools	Fungsi
Scikit-Learn	Pembangunan model machine learning
DecisionTreeClassifier	Model Decision Tree
RandomForestClassifier	Model Random Forest
SVC	Model Support Vector Machine
GridSearchCV	Hyperparameter Tuning
Classification Metrics	Evaluasi model

KUK 2.2. Algoritma untuk teknik pemodelan yang ditentukan dibangun menggunakan tools yang dipilih

Decision Tree

```
In [73]: dt_model = DecisionTreeClassifier(
          class_weight='balanced',
          random_state=42
        )
```

Random Forest

```
In [74]: rf_model = RandomForestClassifier(
          class_weight='balanced',
          random_state=42
        )
```

SVM

```
In [75]: svm_model = SVC(
          class_weight='balanced',
          random_state=42
        )
```

KUK 2.3. Algoritma pemodelan dieksekusi sesuai dengan skenario pengujian dan tools untuk membuat model yang telah ditetapkan

Training model

```
In [76]: dt_model.fit(X_train, y_train)

          rf_model.fit(X_train, y_train)
```

```
svm_model.fit(X_train, y_train)
```

Out[76]:

▼ SVC ⓘ ?

► Parameters

Prediksi

```
In [77]: y_pred_dt = dt_model.predict(X_test)

y_pred_rf = rf_model.predict(X_test)

y_pred_svm = svm_model.predict(X_test)
```

Evaluasi awal

```
In [78]: print("Decision Tree")
print(classification_report(y_test, y_pred_dt))

print("Random Forest")
print(classification_report(y_test, y_pred_rf))

print("SVM")
print(classification_report(y_test, y_pred_svm))
```

Decision Tree

	precision	recall	f1-score	support
0	0.90	0.91	0.90	380
1	0.44	0.42	0.43	67
accuracy			0.83	447
macro avg	0.67	0.66	0.67	447
weighted avg	0.83	0.83	0.83	447

Random Forest

	precision	recall	f1-score	support
0	0.87	0.98	0.92	380
1	0.62	0.19	0.30	67
accuracy			0.86	447
macro avg	0.75	0.59	0.61	447
weighted avg	0.84	0.86	0.83	447

SVM

	precision	recall	f1-score	support
0	0.96	0.85	0.90	380
1	0.47	0.78	0.59	67
accuracy			0.84	447
macro avg	0.71	0.81	0.74	447
weighted avg	0.88	0.84	0.85	447

Hasil berdasarkan evaluasi:

Decision Tree

1. Precision sebesar 44%, artinya dari seluruh pelanggan yang diprediksi akan merespons kampanye, sekitar 44% benar-benar memberikan respons.
2. Recall sebesar 42%, artinya model berhasil menemukan sekitar 42% pelanggan yang benar-benar merespons kampanye.
3. F1-Score sebesar 43%, menunjukkan keseimbangan antara precision dan recall masih tergolong sedang.

Random Forest

1. Precision sebesar 62%, artinya dari seluruh pelanggan yang diprediksi akan merespons kampanye, sekitar 62% benar-benar memberikan respons.
2. Recall sebesar 19%, artinya model hanya berhasil menemukan sekitar 30% pelanggan yang benar-benar merespons kampanye.
3. F1-Score sebesar 30%, menunjukkan keseimbangan precision dan recall setara dengan Decision Tree.

SVM

1. Precision sebesar 47%, artinya dari seluruh pelanggan yang diprediksi akan merespons kampanye, sekitar 27% benar-benar memberikan respons.
2. Recall sebesar 78%, artinya model hanya berhasil menemukan sekitar 16% pelanggan yang benar-benar merespons kampanye.
3. F1-Score sebesar 59%, menunjukkan performa yang kurang baik dalam mendeteksi pelanggan yang merespons kampanye.

Kesimpulan:

1. SVM menjadi model terbaik karena memiliki Recall tertinggi (78%) dan F1-Score tertinggi (59%), sehingga lebih efektif dalam mengidentifikasi pelanggan yang berpotensi merespons kampanye.
2. Decision Tree memiliki performa yang cukup seimbang antara Precision dan Recall, namun masih berada di bawah SVM.
3. Random Forest memiliki Precision tertinggi (62%), tetapi Recall yang rendah menunjukkan banyak pelanggan yang sebenarnya merespons kampanye tidak berhasil terdeteksi.

Saran:

1. Lakukan hyperparameter tuning untuk menemukan kombinasi parameter yang tepat

KUK 2.4. Parameter model algoritma dioptimasi untuk menghasilkan nilai parameter evaluasi yang sesuai dengan skenario pengujian


Optimasi dilakukan untuk memperoleh kombinasi parameter terbaik yang dapat meningkatkan performa model.

Karena dataset memiliki target yang tidak seimbang, optimasi dilakukan menggunakan F1-Score sebagai scoring utama.

Optimasi Decision Tree

```
In [79]: dt_param = {  
    'max_depth':[3,5,7,10],  
    'min_samples_split':[2,5,10],  
    'class_weight':['balanced']  
}  
  
grid_dt = GridSearchCV(  
    DecisionTreeClassifier(random_state=42),  
    dt_param,  
    cv=5,  
    scoring='f1'  
)  
  
grid_dt.fit(X_train, y_train)
```


```
Out[79]:
```



Optimasi Random Forest

```
In [80]: rf_param = {  
    'n_estimators':[100,200],  
    'max_depth':[5,10,None],  
    'min_samples_split':[2,5],  
    'class_weight':['balanced']  
}  
  
grid_rf = GridSearchCV(  
    RandomForestClassifier(random_state=42),  
    rf_param,  
    cv=5,  
    scoring='f1'  
)  
  
grid_rf.fit(X_train, y_train)
```

```
Out[80]:
```




Optimasi SVM

```
In [81]: svm_param = {
    'C': [0.1, 1, 10],
    'kernel': ['linear', 'rbf'],
    'class_weight': ['balanced']
}

grid_svm = GridSearchCV(
    SVC(random_state=42),
    svm_param,
    cv=5,
    scoring='f1'
)

grid_svm.fit(X_train, y_train)
```

```
Out[81]:
```



```
In [82]: print("Decision Tree:", grid_dt.best_params_)
print("Random Forest:", grid_rf.best_params_)
print("SVM:", grid_svm.best_params_)
```

Decision Tree: {'class_weight': 'balanced', 'max_depth': 10, 'min_samples_split': 2}

Random Forest: {'class_weight': 'balanced', 'max_depth': 5, 'min_samples_split': 5, 'n_estimators': 200}

SVM: {'C': 1, 'class_weight': 'balanced', 'kernel': 'rbf'}

UNIT #9 - Mengevaluasi Hasil Pemodelan

Kode unit: J.62DMI00.014.1

[Kembali ke Daftar Isi](#)

Elemen 1 - 1. Menggunakan model dengan data riil

KUK 1.1. Data baru untuk evaluasi pemodelan dikumpulkan sesuai kebutuhan yang mengacu kepada parameter

Data testing yang telah dipisahkan pada tahap sebelumnya digunakan sebagai data evaluasi. Data ini tidak pernah digunakan selama proses pelatihan model sehingga dapat menggambarkan kemampuan model dalam melakukan prediksi terhadap data baru.

```
In [86]: print('X_test:', X_test.shape)
        print('y_test:', y_test.shape)
```

```
X_test: (447, 23)
y_test: (447,)
```

KUK 1.2. Model diuji dengan menggunakan data riil yang telah dikumpulkan

Decision Tree

```
In [105... y_pred_dt = grid_dt.predict(X_test)
```

Random Forest

```
In [108... y_pred_rf = grid_rf.predict(X_test)
```

SVM

```
In [109... y_pred_svm = grid_svm.predict(X_test)
```

Elemen 2 - Menilai hasil pemodelan

KUK 2.1. Keluaran pengujian model dinilai berdasarkan metrik kesuksesan

Evaluasi Decision Tree

```
In [110... dt_accuracy = accuracy_score(y_test, y_pred_dt)
dt_precision = precision_score(y_test, y_pred_dt)
dt_recall = recall_score(y_test, y_pred_dt)
dt_f1 = f1_score(y_test, y_pred_dt)
```

Evaluasi Random Forest

```
In [111... rf_accuracy = accuracy_score(y_test, y_pred_rf)
rf_precision = precision_score(y_test, y_pred_rf)
rf_recall = recall_score(y_test, y_pred_rf)
rf_f1 = f1_score(y_test, y_pred_rf)
```

Evaluasi SVM

```
In [112... svm_accuracy = accuracy_score(y_test, y_pred_svm)
svm_precision = precision_score(y_test, y_pred_svm)
svm_recall = recall_score(y_test, y_pred_svm)
svm_f1 = f1_score(y_test, y_pred_svm)
```

Perbandingan Evaluasi antar Model

```
In [113... evaluation_result = pd.DataFrame({
    'Model': ['Decision Tree', 'Random Forest', 'SVM'],
    'Accuracy': [dt_accuracy, rf_accuracy, svm_accuracy],
```

```
'Precision': [dt_precision, rf_precision, svm_precision],
'Recall': [dt_recall, rf_recall, svm_recall],
'F1-Score': [dt_f1, rf_f1, svm_f1]
})

evaluation_result
```

Out[113...

	Model	Accuracy	Precision	Recall	F1-Score
0	Decision Tree	0.854586	0.512821	0.597015	0.551724
1	Random Forest	0.843400	0.483871	0.671642	0.562500
2	SVM	0.836689	0.472727	0.776119	0.587571

Kesimpulan:

Hasil evaluasi menunjukkan bahwa meskipun Random Forest memiliki Accuracy tertinggi sebesar 86,13%, model tersebut memiliki Recall yang rendah sebesar 19,40%, sehingga kurang efektif dalam mendeteksi pelanggan yang merespons kampanye. Sebaliknya, model SVM menghasilkan keseimbangan terbaik antara Precision dan Recall dengan F1-Score sebesar 58,76%. Berdasarkan hasil tersebut, model SVM direkomendasikan sebagai model akhir untuk implementasi prediksi respons pelanggan.

Confussion Matrix Decision Tree

In [114...

```
cm_dt = confusion_matrix(
    y_test,
    y_pred_dt
)

cm_dt
```

Out[114...

```
array([[342,  38],
       [ 27,  40]])
```

Hasil:

- 342 pelanggan tidak merespons dan berhasil diprediksi benar.
- 38 pelanggan merespons dan berhasil diprediksi benar.
- 27 pelanggan diprediksi merespons padahal tidak.
- 40 pelanggan sebenarnya merespons tetapi gagal terdeteksi.

Confussion Matrix Random Forest

In [115...

```
cm_rf = confusion_matrix(
    y_test,
    y_pred_rf
)

cm_rf
```

Out[115...

```
array([[332,  48],
       [ 22,  45]])
```

Hasil:

- 332 pelanggan tidak merespons dan berhasil diprediksi benar.
- Hanya 48 pelanggan yang merespons berhasil ditemukan.
- Sebanyak 45 pelanggan yang merespons justru tidak terdeteksi.

Confussion Matrix SVM

```
In [116... cm_svm = confusion_matrix(
    y_test,
    y_pred_svm
)

cm_svm
```

```
Out[116... array([[322,  58],
        [ 15,  52]])
```

Hasil:

- Berhasil menemukan 52 dari 67 pelanggan yang merespons.
- Hanya kehilangan 15 pelanggan yang merespons.
- Memang menghasilkan false positive lebih banyak (58).

KUK 2.2. Hasil penilaian didokumentasikan sesuai standar yang berlaku

```
In [117... evaluation_result
```

```
Out[117...
```

	Model	Accuracy	Precision	Recall	F1-Score
0	Decision Tree	0.854586	0.512821	0.597015	0.551724
1	Random Forest	0.843400	0.483871	0.671642	0.562500
2	SVM	0.836689	0.472727	0.776119	0.587571

Hasil evaluasi model didokumentasikan berdasarkan metrik Accuracy, Precision, Recall, dan F1-Score untuk menentukan model yang paling sesuai dalam memprediksi respons pelanggan terhadap kampanye marketing.

Tiga algoritma klasifikasi yang diuji yaitu Decision Tree, Random Forest, dan Support Vector Machine (SVM). Seluruh model telah melalui proses optimasi hyperparameter menggunakan GridSearchCV untuk memperoleh performa terbaik.

Berdasarkan hasil evaluasi, model Decision Tree memperoleh Accuracy sebesar 85,46%, Precision sebesar 51,28%, Recall sebesar 59,70%, dan F1-Score sebesar 55,17%. Model ini menunjukkan kemampuan yang cukup baik dalam mengidentifikasi pelanggan yang merespons kampanye.

Model Random Forest memperoleh Accuracy sebesar 84,34%, Precision sebesar 48,39%, Recall sebesar 67,16%, dan F1-Score sebesar 56,25%. Hasil tersebut menunjukkan bahwa

model mampu mendeteksi pelanggan yang merespons kampanye dengan lebih baik dibandingkan Decision Tree.

Model Support Vector Machine (SVM) memperoleh Accuracy sebesar 83,67%, Precision sebesar 47,27%, Recall sebesar 77,61%, dan F1-Score sebesar 58,76%. Meskipun memiliki Accuracy yang sedikit lebih rendah dibandingkan model lainnya, SVM menghasilkan nilai Recall dan F1-Score tertinggi sehingga mampu memberikan keseimbangan terbaik antara ketepatan prediksi dan kemampuan mendeteksi pelanggan yang merespons kampanye.

Berdasarkan hasil tersebut, model Support Vector Machine (SVM) dipilih sebagai model terbaik karena memiliki nilai F1-Score tertinggi sebesar 58,76% dan Recall tertinggi sebesar 77,61%. Hasil ini menunjukkan bahwa model mampu mengidentifikasi sebagian besar pelanggan yang berpotensi merespons kampanye marketing, sehingga lebih sesuai dengan tujuan bisnis perusahaan.

Kesimpulan

Model SVM direkomendasikan sebagai model akhir untuk prediksi respons pelanggan terhadap kampanye marketing karena memberikan performa terbaik berdasarkan evaluasi menggunakan Accuracy, Precision, Recall, dan F1-Score setelah dilakukan optimasi hyperparameter.

--- Copyright © 2026 Kursus Data Science, Universitas Gunadarma <https://www.hpc-hub.gunadarma.ac.id/>